Part 3：OpenClaw 部署与使用费用分析

> *OpenClaw 本身免费，但驱动它的大模型不是——这一章帮你把"话费"算清楚。*

引言

"OpenClaw 是免费的。"——这句话对也不对。OpenClaw 本身确实是 MIT 开源免费软件，但它需要连接大模型才能工作，就像一台手机免费送你，你还得交话费才能打电话。那这笔"话费"到底多少？答案是：从每月 **¥8** 到 **¥16,200** 不等。听起来差距骇人？别急，读完这章你会发现，大多数人每月一杯奶茶的钱就够了。

> *重要提示：本章所有价格数据为 **2026 年 3 月参考价**。大模型定价频繁变动（而且几乎只会越来越便宜），请以各供应商官方页面的实时报价为准。月度费用基于预设的 Token 消耗量假设，实际费用因使用模式而异。汇率统一按 **1 USD ≈ 7.2 CNY** 计算。*

3.1 Token 与 API 计费基础

在算账之前，我们需要先搞懂一个概念：**Token**。这是大模型 API 计费的最小单位，理解了它，后面的费用表格你就能看得明明白白。

什么是 Token？

Token 是大模型处理文本的最小"颗粒"。你可以把它理解成文字的"字节"——不完全等于一个字或一个词，但非常接近：

语言	换算关系	示例
中文	1 个汉字 ≈ 1-2 tokens	"你好世界" ≈ 4-6 tokens
英文	1 个单词 ≈ 1 token	"Hello World" ≈ 2 tokens
代码	1 行代码 ≈ 3-10 tokens	`print("hello")` ≈ 5 tokens

API 计费分两部分：**输入 Token**（你发给模型的内容）和**输出 Token**（模型回复你的内容）。输出通常比输入贵 2-5 倍——因为输出需要模型逐字"思考"生成，而输入只是"阅读"。

这就像打电话：**听别人说话不太费钱，自己说话才费钱。**

"百万 Token"是什么概念？

API 定价通常以"每百万 Token"（$/M 或 ¥/M）为单位。百万 Token 听起来很抽象，我们换算成日常语言：

量级	约等于	对应使用量
1K tokens	500-750 个中文字	一次普通对话的一个来回
100K tokens	5-7.5 万字	一天 50 轮日常对话
1M tokens	50-75 万字	一本厚书的全部内容
3M tokens	150-225 万字	**场景 A 的一个月用量**

换句话说，**1 百万 Token ≈ 你和 AI 聊一本书那么多的内容**。以后看到 "¥2/M tokens"，你就知道：花 2 块钱，能和 AI 聊一整本书的量。

缓存机制：省钱的隐藏武器

很多 API 提供商支持 **Prompt Caching**（提示词缓存）——如果你每次对话都发送相同的系统提示词，第二次开始就不用全价付费了。

这和 OpenClaw 的关系特别大：OpenClaw 的系统提示词包含 52 个技能描述，约 **15,000+ tokens**。每次对话都会发送这段内容。如果没有缓存，光系统提示词每轮就要花一笔钱；有了缓存，**这部分成本直降 90%**。

提供商	缓存命中价格	对比正常价格	节省幅度
DeepSeek	¥0.2/M	¥2/M	**90%**
Anthropic (Claude)	正常价的 10%	全价	**90%**
OpenAI	正常价的 50%	全价	**50%**

> *九天提醒：后面所有的费用计算中，DeepSeek 的输入价格都按 50-70% 缓存命中率计算（OpenClaw 有大量重复系统提示词，实际命中率通常更高）。这不是在给 DeepSeek "开后门"，而是反映真实使用场景。*

3.2 在线模型定价全景

了解了 Token 计费的基本逻辑，我们来看看市面上主流大模型到底怎么定价。先给一个全局视角，再分国内、国外详细展开。

模型价格阶梯总览

下面这张表是我们的"价格地图"——从免费到天价，一目了然：

价格层级	代表模型	输入价格 ($/M)	输出价格 ($/M)	月费估算 (场景 A·3M TOKENS)
免费	ERNIE Speed / GLM-4.7-Flash	$0	$0	**¥0**
极低	DeepSeek Chat 缓存命中	$0.028	$0.42	**~¥12**
经济	Qwen3.5-Plus / GPT-4o-mini	$0.11~0.15	$0.60~0.67	**~¥8~16**
主流	Gemini 2.5 Flash / GPT-5-Mini	$0.25~0.30	$2.00~2.50	**~¥49~60**
高端	Claude Sonnet 4.6 / Kimi K2.5	$0.60~3.00	$3.00~15.00	**~¥130~389**
旗舰	Claude Opus 4.6 / GPT-5.4	$2.50~5.00	$15.00~25.00	**~¥400~650**
顶级	GPT-5.4 Pro	$15~30	$60~180	**¥2,000+**



几个关键发现：

- 从免费到顶级，价差超过 **1000 倍**——选对模型比什么优化都管用
- 经济层是性价比甜蜜点：月费 ¥8-16，能力足以应付日常工作
- 高端层（Claude Sonnet）和经济层的月费差距是 10-50 倍，但在 Agent 编排、Tool Calling 等高级能力上有质的飞跃

国内模型详细定价（学员最关心）

国内模型是大多数中国用户的首选：无需代理、响应快、中文能力强。我们按性价比从高到低排列：

模型	输入价格 (¥/M)	输出价格 (¥/M)	免费额度	亮点	九天推荐场景
ERNIE Speed	免费	免费	无限	零成本入门	🆓 体验 / 简单问答
GLM-4.7-Flash	免费	免费	无限	零成本入门	🆓 体验 / FAQ 兜底
DeepSeek Chat V3.2	¥0.2 (缓存) / ¥2	¥3	500 万 tokens	性价比之王	💰 日常主力
Doubao-1.5-lite	¥0.3	¥0.6	每日 50 万	极致低成本	💰 轻量任务
Qwen3.5-Plus	¥0.8	¥4.8	90 天免费	国内日常首选	💰 中文场景首选
Kimi K2.5	~¥4.3	~¥21.6	—	最新旗舰	💎 复杂推理

> *九天点评：国内模型的"内卷"是用户的福音。DeepSeek 缓存命中 ¥0.2/M 的价格，放到全球市场都是最低档；Qwen3.5-Plus 不到 1 元/百万 Token 的输入价，性能却接近 GPT-4o。如果你的使用场景以中文为主、不需要顶级 Agent 能力，国内模型完全够用，而且非常便宜。*

国外模型定价速览

国外模型的核心价值在于**顶级能力**，尤其是 Claude 系列在 Agent 编排和 Tool Calling 上的表现，目前国内模型还难以企及。

模型	输入 ($/M)	输出 ($/M)	亮点	九天推荐场景
GPT-4.1-Nano	$0.05	$0.20	极致低成本	💰 路由/分发 Agent
GPT-5-Mini	$0.25	$2.00	性价比之王	💰 通用开发
Gemini 2.5 Flash	$0.30	$2.50	超高性价比 + 免费层	💰 长上下文处理
Claude Haiku 4.5	$1.00	$5.00	轻量快速	💎 快速响应场景
Claude Sonnet 4.6	$3.00	$15.00	**OpenClaw 首选**	💎 Agent 核心引擎
Claude Opus 4.6	$5.00	$25.00	最强 Agent / 编程	👑 顶级推理决策
GPT-5.4	$2.50	$15.00	最强通用旗舰	👑 复杂多模态

> *九天点评：国外模型贵有贵的道理。Claude Sonnet 4.6 是目前公认的 Agent 场景最佳模型——它在多步推理、工具调用准确性、错误恢复能力上的表现，是同价位国内模型的数倍。如果你用 OpenClaw 做严肃的自动化工作流，Claude Sonnet 的"溢价"物有所值。*

3.3 四大场景费用拆解

纸上的价格表看完了，但你真正关心的问题一定是：**"我每个月到底要花多少钱？"**

我们设计了四个典型使用场景，从轻度到重度，逐个算清楚。

> *计算假设说明（透明是信任的基础）：*

> | *参数* | *设定值* | *说明* |
> | --- | --- | --- |
> | *月度 Token 消耗* | *日均消耗 × 30 天* | *—* |
> | *输入/输出比例* | *因场景而异（见各场景标注）* | *编程场景输出占比更高* |
> | *DeepSeek 缓存命中率* | *50-70%（因场景而异）* | *OpenClaw 有大量重复系统提示* |
> | *汇率* | *1 USD ≈ 7.2 CNY* | *2026 年 3 月参考* |
> | *免费模型不计费* | *ERNIE Speed / GLM-Flash = ¥0* | *无限免费额度* |

场景 A：日常工作助手

使用画像：你是一名白领或学生，每天用 OpenClaw 处理日常事务——查资料、写邮件、整理笔记、翻译文档，大约 **50 轮对话/天**。

Token 消耗估算：

- 每轮对话平均 2,000 tokens（含系统提示词分摊）
- 日消耗：50 轮 × 2,000 = 100,000 tokens
- 月消耗：**~3M tokens**（输入/输出各占 50%，即各 1.5M）

模型	月费 (¥)	生活类比
ERNIE Speed / GLM-Flash	**¥0**	白嫖，一分不花
Qwen3.5-Plus	**¥8**	一瓶可乐 🥤
DeepSeek Chat	**¥12**	一杯奶茶 🧋
GPT-5.4-nano	**¥16**	一杯美式 ☕
GPT-5-Mini	**¥49**	两杯星巴克
Claude Haiku 4.5	**¥130**	一顿火锅 🍲
Claude Sonnet 4.6	**¥389**	一顿大餐 🦞

> *场景 A 推荐：*
>
> 🥇 ***Qwen3.5-Plus（¥8/月）——一瓶可乐的价格，中文能力强，国内直连速度快，新用户还有 90 天免费期。日常工作助手的不二之选。***

> 🥈 ***DeepSeek Chat（¥12/月）——一杯奶茶的价格，通用能力更强一些（英文、推理），V3.2 版本编程能力也不错。***
>
> *对于日常场景，不建议使用 Claude Sonnet 或 Opus——就像上班通勤不需要开跑车，¥8-12/月的模型完全够用。*

场景 B：复杂项目开发

使用画像：你是一名开发者，每天大量使用 OpenClaw 辅助编程——写代码、做 Code Review、调试问题、生成文档，**200+ 轮对话/天**。

Token 消耗估算：

- 编程场景平均每轮 2,500 tokens（代码块更长）
- 日消耗：200 轮 × 2,500 = 500,000 tokens
- 月消耗：**~15M tokens**（输入 40% = 6M，输出 60% = 9M——代码生成占比高）

模型	月费 (¥)	体验级别
DeepSeek Chat	**¥34**	够用，V3.2 编程能力强
Qwen3.5-Plus	**¥48**	中文文档/注释更自然
混合方案（DeepSeek + Claude Sonnet）	**¥200-400**	推荐：兼顾成本和质量
Claude Sonnet 4.6	**¥1,102**	最强体验，价格不菲
Claude Opus 4.6	**¥1,836**	极致能力，企业级预算

混合方案怎么用？很简单：

```
日常编码（70% 工作量）→ DeepSeek Chat    ≈ ¥24
复杂架构/调试（30% 工作量）→ Claude Sonnet  ≈ ¥330
混合总计                                    ≈ ¥200-400/月
```

> *场景 B 推荐：*
>
> 🥇 ***混合方案（¥200-400/月）——这是性价比的甜蜜点。日常的 CRUD 代码、文档生成交给 DeepSeek（便宜、够快），遇到复杂的系统设计、疑难 Bug 调试再切到 Claude Sonnet（贵但值）。OpenClaw 支持多 Provider 配置，切换模型只需改一行配置，零成本。***

> 🥈 *纯 DeepSeek（¥34/月）——如果预算有限，V3.2 的编程能力已经很强。绝大多数常规开发任务它都能胜任。*
>
> 💡 *省钱技巧：编程场景输出占比高（60%），而输出比输入贵 2-5 倍。适当使用 `maxTokens` 限制单次输出长度，能有效控制费用。*

场景 C：全自动 AI 数字人

使用画像：你运营一个 AI 数字人——7×24 小时处理多通道消息，包括客服问答、社交媒体管理、邮件自动回复，**1000+ 轮对话/天**。

Token 消耗估算：

- 客服/社交场景平均每轮 2,000 tokens
- 日消耗：1,000 轮 × 2,000 = 2,000,000 tokens
- 月消耗：**~60M tokens**（输入 60% = 36M，输出 40% = 24M——读多写少，客服场景需要读取大量上下文）
- DeepSeek 按 **70% 缓存命中率**计算（客服场景有大量重复的知识库上下文和系统提示）

模型	月费 (¥)
DeepSeek Chat（缓存 70%）	**¥99**
GPT-5.4-nano	**¥143**
Qwen3.5-Plus	**¥144**
GPT-5-Mini	**¥410**
Claude Haiku 4.5	**¥1,123**
Claude Sonnet 4.6	**¥3,370**

> *场景 C 推荐：*
>
> 🥇 ***DeepSeek + 免费模型路由（¥50-100/月）**——这是数字人场景的最优解。策略如下：*

> | *消息类型* | *占比* | *路由到* | *单月费用* |
> |---|---|---|---|
> | *简单问候/FAQ* | *40%* | *GLM-Flash（免费）* | *¥0* |
> | *常规咨询* | *45%* | *DeepSeek Chat* | *~¥45* |
> | *复杂投诉/升级* | *15%* | *Qwen3.5-Plus* | *~¥22* |
> | *合计* | *100%* | *—* | ***~¥67*** |
>
> *关键在于路由：大部分客服消息都是重复的（"几点发货？""怎么退款？"），用免费模型就能搞定。只有复杂问题才需要调用付费模型。*

场景 D：工业级 Agent Swarm（一人公司）

使用画像：你是一个"一人公司"创始人，用多 Agent 协作实现全自动化——数据分析 Agent、内容生产 Agent、代码开发 Agent、项目管理 Agent 同时运转，**5M+ tokens/**天。

Token 消耗估算：

- 多 Agent 协作，消息链路密集
- 月消耗：**~150M tokens**（输入/输出各占 50%，即各 75M）

方案	月费 (¥)	说明
纯 **DeepSeek**	**¥310**	能力有限，简单任务可用
多模型混合（推荐）	**¥4,700**	四层路由，性价比最高
纯 **Claude Sonnet**	**¥9,720**	省心但贵
纯 **Claude Opus**	**¥16,200**	极致但奢侈

混合方案的四层架构：

AGENT 角色	推荐模型	TOKEN 占比	月费 (¥)
路由/分发 Agent	GPT-4.1-Nano / ERNIE Free	10% (15M)	~¥11
日常执行 Agent（3-5 个）	DeepSeek Chat V3.2	50% (75M)	~¥155
核心决策 Agent	Claude Sonnet 4.6	30% (45M)	~¥2,916
顶级推理 Agent	Claude Opus 4.6	10% (15M)	~¥1,620
混合总计	—	100% (150M)	**~¥4,700**

> *场景 D 推荐：*
>
> *🥇 多模型四层混合（**¥4,700**/月）——对比纯 Claude Sonnet 省 **51.6%**，对比纯 Opus 省 **71.0%**。核心思想是"好钢用在刀刃上"：*
>
> - *路由 Agent 不需要"聪明"，用免费或极低价模型*
> - *执行层 Agent 做的是确定性高的任务（发邮件、查数据），DeepSeek 足矣*
> - *只有决策和推理才需要 Claude 的顶级能力*
>
> *💡 ¥4,700/月听起来不少，但如果这套 Agent Swarm 能替代 1-2 名员工的工作量，这是全世界最便宜的"员工"了。*

四场景费用对比一览

场景	月 TOKEN 消耗	最低方案	推荐方案	高端方案
A 日常助手	3M	¥0（免费模型）	**¥8-12**	¥389
B 项目开发	15M	¥34	**¥200-400**	¥1,836
C AI 数字人	60M	¥67（路由方案）	**¥50-100**	¥3,370
D Agent Swarm	150M	¥310	**¥4,700**	¥16,200

3.4 本地部署费用分析

看完在线 API 的费用，你可能在想："**如果我自己买张显卡跑模型，是不是更便宜？**"

答案可能出乎意料——**大多数情况下，不是。**

GPU 硬件成本速查

GPU	显存	适合模型	购买价 (¥)	云租赁 (¥/时)	24/7 月租 (¥)
RTX 4060 Ti	16GB	14B Q4 量化	3,200	—	—
RTX 4090	24GB	32B Q4 量化	14,000-20,000	2.68	1,930
RTX 5090	32GB	32B Q4（宽裕）	16,999 起	—	—
A800 80GB	80GB	72B Q4 量化	80,000-120,000	5.98	4,306

> *注：RTX 4090 已停产，市场价远超原价 $1,599。以上为 2026 年 3 月二手/库存参考价。*

本地 vs 在线：各场景真实对比

这张表是"本地部署值不值"的终极答案：

场景	在线 API 月费	云 GPU 租赁月费	自购 GPU 月电费	结论
A 日常助手	¥8-50	¥643-1,930	~¥30	在线碾压：¥8 vs ¥643，差 80 倍
B 项目开发	¥34-1,102	¥1,794-4,306	~¥60-80	在线更划算：即使用 Sonnet 也比云 GPU 便宜
C 数字人	¥99-3,370	¥1,930-4,306	~¥150-250	在线性价比高：DeepSeek ¥99 vs 云 GPU ¥1,930
D Agent Swarm	¥4,700	¥8,612+	~¥500+	在线为主：灵活性和能力都更强

结论很清晰：**在每一个场景中，在线 API 的月度费用都低于本地部署**（至少在使用云 GPU 租赁的情况下）。

自购 GPU 回本周期分析

"等等，"你可能会说，"自购 GPU 不是只用付电费吗？时间长了应该能回本吧？"

我们来算一算：

案例：**RTX 4090（¥16,000）跑 Qwen3.5-32B Q4**

对比方案	在线月费	本地月费（电费）	月节省	回本周期
vs Qwen3.5-Plus	¥8	¥60	**-¥52**（反而更贵）	❌ 永远不回本
vs DeepSeek Chat	¥34	¥60	**-¥26**（反而更贵）	❌ 永远不回本
vs 混合方案	¥400	¥60	¥340	**47 个月**（近 4 年）
vs Claude Sonnet 纯用	¥1,102	¥60	¥1,042	**15 个月**

残酷的真相是：

1. 如果对比 DeepSeek/Qwen 等国内低价模型，自购 GPU 的电费反而比 **API 更贵——永远不回本**
2. 即使对比 Claude Sonnet，也需要 15 个月才能回本——但**本地 32B 模型的能力远不如 Claude Sonnet**
3. GPU 还有折旧、散热、噪音、维护等隐性成本

什么时候该本地部署？

说了这么多"在线更便宜"，并不是说本地部署毫无意义。以下四种场景，本地部署是刚需：

场景	原因	推荐方案
数据绝对不能出本机	金融、医疗、政府等合规场景	自购 RTX 4090 + Qwen3.5-32B
完全无外网	离线/内网/涉密环境	自购硬件 + Ollama
对延迟极端敏感	本地首 Token 50ms vs 在线 200ms-2s	自购高端 GPU + vLLM
长期高强度 + 预算充足	愿意承担初始投入和能力差距	自购 RTX 5090 / A800

> *九天总结：纯经济角度，本地部署很难比在线 API 便宜。**本地部署的核心价值是数据隐私和离线能力，而不是省钱。**如果你没有明确的合规/离线需求，建议把买显卡的钱省下来，直接用在线 API——体验更好、能力更强、总成本更低。*

3.5 成本优化策略清单

不管你选择哪种方案，以下六大策略都能帮你把费用再压一压。

六大省钱策略

#	策略	节省幅度	实施难度	说明
1	多模型路由	50-70%	⭐⭐	简单任务用便宜模型，复杂任务用好模型。OpenClaw 原生支持多 Provider 切换
2	**Prompt Caching**	50-90% 输入费	⭐	OpenClaw 系统提示词 15K+ tokens 可自动缓存，大部分提供商默认开启
3	**Batch API**	50%	⭐⭐	非实时任务（报告生成、数据分析）走异步批处理，24 小时内返回
4	限制输出长度	20-40%	⭐	设置 `maxTokens` 参数，避免模型"长篇大论"。日常问答 500 tokens 足够
5	关闭 **Thinking** 模式	10-50 倍	⭐	推理模式（如 o3、DeepSeek-Reasoner）极费 Token。日常任务**务必关闭**
6	免费模型兜底	100%	⭐	ERNIE Speed / GLM-Flash 完全免费，用作路由兜底或简单任务处理

> *九天提醒：策略 5 特别容易被忽视。很多人开着"深度思考"模式聊天，殊不知一个推理问题可能消耗 10,000+ tokens 的思考过程，而日常对话只需要 200 tokens。**日常使用务必关闭 Thinking/Reasoning 模式，需要深度推理时再手动开启。***

阶梯式模型选择建议

根据你的预算和需求，我们给出从免费到极致的阶梯式推荐：

阶梯	月预算	推荐模型	适合人群
FREE	**¥0**	ERNIE Speed / GLM-4.7-Flash	学生、体验者、轻度用户
💰	**¥10-50**	DeepSeek Chat / Qwen3.5-Plus	白领、个人开发者、日常办公
💎	**¥200-400**	DeepSeek + Claude Sonnet 混合	专业开发者、中度 Agent 使用者
👑	**¥1,000+**	Claude Sonnet / Opus 为主	重度开发者、小型创业团队
🏢	**¥5,000+**	多模型四层混合 + Claude Opus	一人公司、全自动 Agent Swarm



选择阶梯的核心原则：**从低往高试，而不是从高往低降**。先用免费模型体验 OpenClaw 的基本功能，觉得不够用再升级到 DeepSeek/Qwen，还不满足再加入 Claude——这样你始终知道每一分钱花在了哪里。

3.6 费用总结与决策建议

三个章节走下来，我们已经把 OpenClaw 的"账本"翻了个底朝天。现在是时候给出最终结论了。

核心结论

结论	说明
日常使用 = 在线 API	DeepSeek/Qwen 月费 ¥10-50，远低于任何本地方案。一杯奶茶的钱，换一个全天候 AI 助手
专业场景 = 在线混合	简单任务用便宜模型 + 复杂任务用 Claude，混合策略省 50%+。这是性价比最高的玩法
数据敏感 = 本地部署	自购 RTX 4090 + Qwen3.5-32B，接受能力差距换取数据安全。本地部署的价值是隐私，不是省钱
Agent Swarm = 在线为主	本地部署成本是在线的 2-3 倍，且灵活性差、能力受限
越复杂的场景越推荐 Claude	Opus/Sonnet 在 Agent 编排、Tool Calling 上有质的优势，复杂任务值得花这个钱

九天推荐：不同预算的最优选择

月预算	推荐模型组合	适合场景	一句话建议
¥0	ERNIE Speed + GLM-Flash	基础体验、学习测试	零成本入门，先跑起来再说
¥10-50	DeepSeek Chat / Qwen3.5-Plus	日常工作助手	**大多数人的最优选择**
¥200-400	DeepSeek + Claude Sonnet 混合	复杂项目开发	**性价比天花板**
¥1,000+	Claude Sonnet / Opus 为主	工业级 Agent、一人公司	追求极致能力
¥5,000+	多模型四层混合 + Claude Opus	全自动 Agent Swarm	用 AI 替代团队

一句话总结

> *大多数人每月花 **¥10-50**（一杯奶茶到一杯星巴克），就能拥有一个强大的 AI 助手。如果你对能力有更高追求，每月 **¥200-400** 的混合方案是性价比最高的选择。本地部署更适合"数据不出门"的场景，而不是"省钱"的场景。*